

Revisão crítica de arquitetura de sistema de indexação ▾

1.1.md
316 linhas

MD

Atue como um Principal AI Architect realizando uma revisão crítica do documento anexado.

Seu objetivo NÃO é elogiar o documento.

Procure:

1. Estimativas otimistas demais.
2. Suposições sem evidência.
3. Riscos arquiteturais ignorados.

Mostrar mais

Identificou falhas estruturais, estimativas otimistas e lacunas críticas em segurança >

Segue minha revisão crítica como Principal AI Architect. O documento tem um esqueleto razoável e cobre os temas certos em nível superficial, mas como **análise de viabilidade** ele não está pronto para entrega: faltam três pilares (custo, segurança/permissoes e avaliação), há erros factuais e estruturais, e várias estimativas são otimistas sem reconhecer incerteza. Vou ser direto.

Problemas estruturais e de qualidade do próprio documento

1. Seções faltando (1.3 e 3). O texto pula de 1.2 para um cabeçalho "Estratégia Recomendada" órfão (sobre links/macros/Confluence) e depois para 1.4 — não existe seção 1.3 com seu "Desafio". O corpo também salta da Seção 2 direto para a Seção 4; a Seção 3 inteira sumiu. *Por que importa:* um documento de viabilidade técnica com numeração quebrada e seção órfã passa a impressão de que foi montado às pressas e mina a credibilidade técnica. *Correção:* reconstruir a 1.3 (provavelmente "Confluence/macros/links internos") com Desafio + Impacto + Estratégia, e identificar o que era a Seção 3 (provavelmente "Limites de contexto e seleção de chunks", hoje misturada na Seção 2).

2. Frase quebrada na OCR. "Executar OCR utilizando durante chunking" está gramaticalmente incompleta e tecnicamente errada: OCR ocorre na **ingestão**, antes do chunking, e nenhum motor é nomeado. *Correção:* "Executar OCR na ingestão (ex.: Azure Document Intelligence / AWS Textract para tabelas, Tesseract como fallback), antes do chunking" e configurar para **português** (acentuação, ç, ã) — omissão relevante porque OCR default em inglês degrada termos com acento.

Estimativas otimistas e suposições sem evidência

3. Tokenização calculada como se fosse inglês. A regra "1 token $\approx$ 0,75 palavra" é para inglês. Em português a tokenização é menos eficiente (frequentemente 1,3–1,8 token/palavra reais nos tokenizers atuais, por causa de acentos e morfologia). *Por que importa:* os 6,3M de tokens podem estar subestimados em 30–80%, e tudo que deriva disso (custo, nº de chunks, storage) herda o viés otimista. *Correção:* recalibrar empiricamente com uma amostra real de 20–30 documentos do corpus da NovaTech e usar uma **faixa**, não um número único.

4. Estimativas pontuais sem variância. "10 páginas/doc", "500 palavras/página (conservador)", "2.000 palavras/planilha" são chutes sem fonte. Planilhas com fórmulas interdependentes, quando você serializa valores + fórmulas + regras de negócio (como o próprio doc recomenda em 1.4), explodem muito acima de 2.000 palavras. *Correção:* substituir por faixas (P50/P90) medidas em amostra e somar o **overlap** de chunking (50–100 tokens sobre chunks de 300–500 = +10–30% de chunks e embeddings, hoje ignorado).

5. "Capacidade teórica" de 396 chunks é um cálculo irrelevante. Calcular quantos chunks cabem na janela de contexto mistura dois conceitos: o ponto da arquitetura RAG é justamente **não** colocar o corpus no contexto. O número que importa — corpus (~6,3M tokens) é $\sim 31\times$ maior que a janela (200K) — é exatamente o motivo de existir RAG, não uma "capacidade". *Correção:* trocar a narrativa de "capacidade teórica" por "orçamento de contexto por consulta" e justificar a partir de qualidade/custo, não de quanto cabe.

6. Reserva de 2.000 tokens é irreal. Sobram só o system prompt? Falta orçamento para a pergunta do usuário, histórico de conversa, instruções de citação/grounding e a própria resposta gerada. System prompts de RAG corporativo passam fácil de 2.000 tokens. *Correção:* orçamento explícito: system prompt + few-shots, histórico, query, contexto recuperado e teto de output, com folga.

7. Janela de 200K e uso de Opus 4.8 para tudo. O valor de 200K para Opus 4.8 deve ser **verificado** (modelos recentes variam e podem ser maiores). Mais grave: usar o modelo

mais caro para todas as consultas é um erro de design de custo. *Correção*: confirmar a janela na documentação oficial e adotar roteamento por modelo (FAQ/simples em modelo mais barato, casos complexos em Opus).

Custo — ausência total de modelo (lacuna crítica)

8. Não há nenhuma cifra de custo, apesar de "Custo" ser citado como preocupação. Faltam: geração de embeddings (one-time + incremental), hosting do vector DB, API do reranker, e o custo por consulta (chunks de input + output) × volume de chamados projetado. *Por que importa*: "viabilidade" sem custo por consulta e projeção mensal é incompleta — pode ser tecnicamente possível e economicamente inviável. *Correção*: tabela de custo: \$/1M tokens × volume estimado de queries/mês, custo de embeddings (~15-20 mil chunks na primeira carga), reranker e infra, com cenário pessimista (tokenização PT).

Segurança e governança documental (lacuna crítica)

9. Ausência de permission-aware retrieval / security trimming. Em RAG corporativo sobre SharePoint/Confluence, o assistente **não pode** recuperar conteúdo que o usuário não tem permissão de ver. O documento não menciona ACLs, propagação de permissões nem filtragem por identidade. *Por que importa*: sem isso, o sistema vira um vetor de vazamento de dados internos — risco de compliance, não só técnico. *Correção*: indexar ACLs como metadado e aplicar filtro de segurança por identidade (Entra ID/SSO) no momento da busca, com testes de não-vazamento.

10. Governança rasa. "Priorização por data" para documentos conflitantes assume que o mais novo é o correto — nem sempre verdade (rascunho recente vs. política oficial antiga). Faltam: citação de fonte ao usuário, trilha de auditoria das respostas, tratamento de PII, e loop de feedback para respostas erradas. *Correção*: hierarquia de autoridade documental (oficial > rascunho) além de data, atribuição obrigatória de fonte na resposta e log de Q&A para auditoria.

Atualização incremental dos índices

11. "Pipeline incremental" é só um nome, sem mecanismo. Como detectar o que mudou nas atualizações mensais? Como tratar **deleções** e embeddings órfãos? Confluence e SharePoint têm versionamento e webhooks que não são explorados. *Correção*: detecção de delta via change tokens/webhooks do SharePoint Graph e do Confluence, com reconciliação de deleções (tombstones) e reindexação só do que mudou.

Embeddings e retrieval

12. Contradição: "cada tabela vira uma unidade independente" vs. limite do modelo de embedding. Muitos modelos de embedding truncam em ~512 tokens; uma tabela de frete com 15+ colunas estoura isso facilmente. *Por que importa:* a estratégia central da Seção 1.1 falha silenciosamente — a tabela é truncada e o embedding fica incompleto. *Correção:* resumo/serialização semântica da tabela dentro do limite + chunking por blocos de linhas com cabeçalho repetido, ou modelo de embedding de contexto longo escolhido explicitamente.

13. Modelo de embedding não escolhido, e idioma ignorado. O corpus é em português; muitos embeddings são otimizados para inglês e perdem jargão de logística (frete, SLA, modalidade). *Correção:* selecionar modelo multilíngue/PT comprovado e avaliar com o vocabulário de domínio.

14. "Busca híbrida e reranking" sem especificação. Qual método esparsa (BM25?), qual fusão (RRF?), qual reranker, qual latência/custo? Sem detalhe, não dá para validar. *Correção:* definir o stack (ex.: BM25 + denso, fusão RRF, reranker cross-encoder) e medir o overhead de latência do reranker.

15. Sem framework de avaliação (lacuna crítica). O documento afirma "Alta Viabilidade Técnica" e a meta de 12→2 min sem **nenhuma** forma de medir qualidade de resposta: nada de golden set, recall@k, MRR, taxa de alucinação ou baseline de correção. *Por que importa:* a meta declarada é só de **velocidade**; uma resposta rápida e errada piora o atendimento. *Correção:* conjunto de teste rotulado (50–100 perguntas reais), métricas de retrieval e de fidelidade, e critério de aceite antes do go-live.

Lost in the middle e grounding

16. Mitigação simplista do "lost in the middle". "Colocar o importante no início" presume que se sabe qual é o mais importante (é o que o reranker deveria resolver) e ignora que vários modelos atendem bem ao **fim** do contexto também. O efeito vem de papers em modelos antigos; aplicá-lo a Opus sem evidência específica é suposição. *Correção:* validar empiricamente a sensibilidade posicional no modelo escolhido e confiar no reranking + poucos chunks, não em heurística de posição.

17. Grounding tratado como subproduto do retrieval. Busca híbrida e reranking melhoram **recuperação**, não **ancoragem**. Não há estratégia de abstenção ("não sei"), limiar de confiança nem citação obrigatória. *Correção:* exigir citação verificável, permitir abstenção quando o suporte for fraco e medir taxa de alucinação.

Integração e escalabilidade

18. Integração só citada, nunca analisada. A conclusão lista "SharePoint e Teams" como ponto positivo, mas o corpo nunca discute autenticação SSO/Entra ID, rate limits da Graph API e da API do Confluence, framework de bot do Teams, nem polling vs. webhook. *Correção:* seção dedicada de integração com limites de API, modelo de autenticação e estratégia de sincronização.

19. Escalabilidade e concorrência não modeladas. "Volume moderado" considera só o tamanho do corpus, não a carga: rollout no Teams para a empresa toda implica concorrência/QPS, rate limits da API do LLM e custo sob pico — sem isso o reranker pode virar gargalo. *Correção:* estimar usuários concorrentes e QPS de pico, validar limites de taxa da API e custo no cenário de carga.

Nota da análise: 5/10

Estrutura competente e cobertura ampla dos temas certos, mas como **análise de viabilidade** está incompleta e otimista: faltam custo, segurança/permissoes e avaliação (os três pilares que justificariam ou não a "Alta Viabilidade"), há contradição técnica (tabela vs. limite de embedding), estimativas de ponto único sem incerteza, tokenização calculada como inglês, e defeitos de redação/numeração. A classificação "Alta Viabilidade Técnica" não está sustentada pela evidência apresentada.

Mudanças obrigatórias antes da entrega

1. **Adicionar modelo de custo** (embeddings inicial + incremental, vector DB, reranker, custo/consulta $\times$ volume mensal, cenário pessimista PT). Sem isso, não há análise de viabilidade.
2. **Adicionar permission-aware retrieval / security trimming** com ACLs e identidade — bloqueador de compliance.
3. **Adicionar framework de avaliação** (golden set, recall@k, taxa de alucinação, baseline de correção) e amarrar a meta a qualidade, não só a velocidade.
4. **Resolver a contradição tabela $\leftrightarrow$ limite de embedding** com estratégia concreta de serialização/chunking de tabela.
5. **Corrigir as lacunas estruturais** (reconstruir 1.3 e 3, consertar a frase de OCR e nomear o motor/idioma).
6. **Recalibrar tokenização e volume** com amostra real do corpus, usando faixas e incluindo overlap.
7. **Detalhar atualização incremental** (delta via webhooks/change tokens, deleções/tombstones).
8. **Especificar busca híbrida + reranking** (métodos, fusão, reranker, latência) e a estratégia de grounding/abstenção/citação.

Recomendáveis na sequência (não bloqueadores): seção de integração com rate limits e SSO, modelagem de concorrência/escala, e roteamento por modelo para conter custo.

Se quiser, reescrevo qualquer uma dessas seções já no formato corrigido para você incorporar ao documento.

